

B8 — Un lenguaje emergente de compresión para LLMs

Dossier · Fecha: 2026-06-20 · Tema: ¿puede un LLM construir, desde la interacción real del chat, un idioma denso propio para agrupar y reusar conocimiento?

Resumen ejecutivo

La idea de Miguel —que el modelo desarrolle, de abajo hacia arriba y observando el chat troncal, un idioma denso propio (cápsulas en su taquigrafía, agrupadas por volumen/sector) para asimilar conocimiento— **no es fantasía**. Cada pieza de la idea corresponde a una línea de investigación activa, y una de ellas (un paper de enero de 2026) describe algo **casi idéntico** a la versión-herramienta.

Veredicto honesto: instinto correcto y dirección real, pero **no es terreno virgen**. Hay que separar dos versiones: la *versión-herramienta* (un codebook externo aprendido del chat) es construible hoy sin entrenar, pero ya tiene competidores cercanos; la *versión-en-pesos* (que el modelo internalice ese idioma) es research puro, fuera de alcance individual hoy. El movimiento inteligente no es competir de frente en compresión, sino buscar un ángulo diferenciador: personalización + memoria + el *por qué*.

La idea (en términos de Miguel)

En vez de diseñar un idioma desde arriba (lo que exigiría entrenar los pesos del modelo), construir una **herramienta que observe pasivamente la interacción del chat**, mine las frases/conceptos que más se repiten, y arme un **codebook** que crece con el uso — un idioma que *emerge* de cómo Miguel y el modelo realmente hablan. Es, en sus palabras, un *Esperanto* (metáfora de un idioma universal nuevo), y funcionalmente un **"BPE de nivel superior"**: fusionar conceptos frecuentes en códigos cortos, igual que el tokenizador fusiona caracteres frecuentes.

Qué dice la investigación

Razonar en el idioma propio del modelo (espacio latente). *Coconut* (Meta, dic 2024) hace que el modelo razone con vectores continuos en vez de palabras: encadena estados ocultos como "pensamientos continuos". Supera al chain-of-thought clásico en tareas de planificación (97.0% vs 77.5% en ProsQA) usando *menos* tokens [1]. Es la "versión fuerte" del sueño de Miguel — pero requiere entrenamiento progresivo del modelo.

Perfiles por bloques (gist tokens). *Learning to Compress Prompts with Gist Tokens* (Stanford, NeurIPS 2023) comprime un prompt en unos pocos tokens "gist" cacheables y reusables: hasta **26x** de compresión y **40% menos de cómputo**, sin costo extra sobre el fine-tuning normal [2]. Esto es, casi literalmente, los "perfiles como archivos por bloques" de Miguel — pero también vive dentro del modelo (modifica las máscaras de atención).

Emergencia de abajo hacia arriba. Hay toda una línea de *comunicación emergente*: agentes que, interactuando, desarrollan espontáneamente un idioma comprimido. El framework *AI Mother Tongue* muestra comprensión semántica espontánea vía cuantización vectorial [3]; *CELEBI* induce idiomas compositivos a través de un cuello de botella discreto que premia compresión y expresividad a la vez [4]. Esto respalda la intuición de que un idioma puede *emerger* del uso, no diseñarse.

La analogía del BPE es exacta. El tokenizador BPE se "entrena" sobre un corpus fusionando iterativamente el par de símbolos más frecuente en uno nuevo, hasta llegar a un vocabulario [5]. La idea de Miguel es justo eso, un nivel más arriba: fusionar *frases/conceptos* frecuentes de sus chats. No sacó la idea de un paper; la dedujo.

Lo que ya existe (estado del arte) — y la sorpresa

La capa de "comprimir antes de enviar" ya está poblada: **LLMLingua** (Microsoft) logra hasta 20x con un modelo pequeño, sin entrenar, sobre cualquier LLM black-box [7]; hay guías comerciales que prometen ~60% de ahorro [10].

La sorpresa honesta: la versión-herramienta de B8 ya tiene un primo cercano publicado. *Active Context Compression: Autonomous Memory Management in LLM Agents* ("Focus", enero 2026) propone un agente que **consolida sus aprendizajes en un bloque "Knowledge" persistente y poda el historial crudo** [6]. Eso es prácticamente la versión-herramienta de tu idea. Además, hay trabajo en codebooks aprendidos para memoria personalizada [8] y en representaciones de texto comprimidas (ARC-Encoder) [9].

Conclusión: la idea grande está validada por el mundo... y eso significa que **no llegaste primero a la versión obvia**. El hueco real no es "comprimir bloques", es *con qué ángulo* lo haces.

Viabilidad y riesgos (sección crítica)

Versión-herramienta (codebook externo aprendido del chat): - ■ Construible hoy, sin entrenar pesos. Los LLM decodifican su propia taquigrafía casi sin clave. - ■■ El codebook pesa: para que el modelo lo use hay que meterlo en contexto → cuesta tokens. Hay que medir el ahorro **neto**, no el bruto. - ■■ Fragilidad: un idioma personal sobreajusta a un estilo; puede volverse ambiguo en temas nuevos. Y **no transfiere** entre usuarios. - ■■ Competidor cercano (*Focus* [6]): necesitas un diferenciador o serás "otro compresor más".

Versión-en-pesos (latente/gist real [1][2]): - ■ Fuera de alcance individual hoy: requiere entrenamiento, datos y GPUs. (La guía de escalado detallada queda pendiente para cuando el proyecto base esté en pasos firmes, según lo acordado.)

Lo más honesto: en números puros de compresión, la versión-herramienta probablemente **no le gane a LLMLingua**. Su valor tendría que estar en otra parte.

Caminos posibles

- **1. Micro-experimento barato (ya definido).** Tomar unos chats reales de Miguel → top 10-20 frases/conceptos repetidos → asignarles códigos cortos → medir: ¿el ahorro neto (con el codebook incluido) es positivo y el modelo decodifica bien? Esfuerzo bajo, señal alta. Es el primer paso correcto.
- **2. El diferenciador real: fusionar B8 con Engram (el "por qué").** Que el codebook no solo comprima, sino que guarde la *decisión/razón* detrás de cada bloque. Un "idioma con memoria de intención". Eso sí sería nuevo frente a Focus y LLMingua, y conecta con la herramienta hermana que ya empezaste.
- **3. Versión-en-pesos.** Solo con financiamiento o colaboración de research. Aspiracional, no inmediato.

Veredicto

Instinto **correcto**, dirección **real**, pero **no virgen**. La versión construible ya tiene un competidor publicado (Focus, 2026), así que competir de frente en "comprimir bloques" es perder. El movimiento inteligente: hacer el **micro-experimento barato** para validar que el ahorro neto existe, y apostar el diferenciador a lo que nadie está juntando bien — **compresión personal + memoria + el porqué**. Ahí B8 deja de ser "otro compresor" y se vuelve algo tuyo.

Fuentes

- [1] Coconut — Training LLMs to Reason in a Continuous Latent Space (Meta, 2024) — <https://arxiv.org/abs/2412.06769>
- [2] Learning to Compress Prompts with Gist Tokens (Mu, Li, Goodman; Stanford, NeurIPS 2023) — <https://arxiv.org/abs/2304.08467>
- [3] AI Mother Tongue: Self-Emergent Communication in MARL — <https://arxiv.org/pdf/2507.10566>
- [4] CELEBI: Compressive-Expressive Language Emergence — <https://arxiv.org/html/2501.19182v3>
- [5] Neural Machine Translation of Rare Words with Subword Units (BPE; Sennrich et al., 2015) — <https://arxiv.org/pdf/1508.07909>
- [6] Active Context Compression: Autonomous Memory Management in LLM Agents (Focus, 2026) — <https://arxiv.org/abs/2601.07190>
- [7] LLMingua (Microsoft) — <https://llmingua.com/llmingua.html>
- [8] Clustering-driven Memory Compression for On-device LLMs — <https://arxiv.org/pdf/2601.17443>
- [9] ARC-Encoder: learning compressed text representations for LLMs — <https://arxiv.org/pdf/2510.20535>
- [10] Token Optimization guide (Burnwise) — <https://www.burnwise.io/blog/token-optimization-guide>